

In [1]:

```

import numpy as np
import pandas as pd

pd.options.display.max_rows = 20
# Configura pandas para mostrar un
# máximo de 20 filas al imprimir DataFrames.
# Esto ayuda a mantener la salida manejable en la consola.

pd.options.display.max_colwidth = 80
# Configura pandas para que la anchura máxima
# de las columnas sea de 80 caracteres al
# mostrar datos. Esto es útil para asegurarse
# de que las columnas no se truncuen demasiado en la visualización.

pd.options.display.max_columns = 20
# Configura pandas para mostrar un máximo
# de 20 columnas al imprimir DataFrames.
# Similar a max_rows, esto ayuda a
# controlar la cantidad de datos mostrados.

np.random.seed(12345)

import matplotlib.pyplot as plt

plt.rc("figure", figsize=(10, 6)) # Configura matplotlib para que todas
# las figuras tengan un tamaño predeterminado de 10 pulgadas de ancho
# por 6 pulgadas de alto. rc es una función de matplotlib que se
# utiliza para configurar parámetros globales.

np.set_printoptions(precision=4, suppress=True)
# Configura numpy para mostrar los números con una
# precisión de 4 decimales y suprimir el uso de
# notación científica (suppress=True) en la salida impresa.

```

### 3. Tratamiento de datos (Wrangling): Unir (Join), combinar (Combine) y remodelar (Reshape)

En muchas aplicaciones, los datos pueden estar dispersos en varios archivos o bases de datos, o estar organizados de una forma que no es conveniente analizar.

En primer lugar, se introduce el concepto de indexación jerárquica (**Hierarchical Indexing**) en pandas, que se utiliza ampliamente en algunas de estas operaciones.

#### 3.1 Indexación jerárquica

La indexación jerárquica es una característica importante de pandas que le permite tener múltiples (dos o más) niveles de índice en un eje. Otra forma de pensar en ello es que proporciona una manera para que usted pueda trabajar con datos de mayor dimensión

en una forma de menor dimensión. Empecemos con un ejemplo sencillo: crear una Serie con una lista de listas (o arrays) como índice:

```
In [2]: data = pd.Series(np.random.uniform(size=9),
                      index=[["a", "a", "a", "b", "b", "c", "c", "d", "d"],
                             [1, 2, 3, 1, 3, 1, 2, 2, 3]])
data
```

```
Out[2]: a    1    0.929616
         2    0.316376
         3    0.183919
       b    1    0.204560
         3    0.567725
       c    1    0.595545
         2    0.964515
       d    2    0.653177
         3    0.748907
dtype: float64
```

Lo que está viendo es una vista de una Serie con un Multiíndice ( `MultiIndex` ) como índice. Los "huecos" en la visualización del índice significan "use la etiqueta directamente arriba":

```
In [3]: data.index
```

```
Out[3]: MultiIndex([('a', 1),
                     ('a', 2),
                     ('a', 3),
                     ('b', 1),
                     ('b', 3),
                     ('c', 1),
                     ('c', 2),
                     ('d', 2),
                     ('d', 3)],
                    )
```

Con un objeto indexado jerárquicamente, es posible la llamada indexación parcial, que permite seleccionar de forma concisa subconjuntos de los datos:

```
In [4]: data["b"]
```

```
Out[4]: 1    0.204560
       3    0.567725
dtype: float64
```

```
In [5]: data["b":"c"]
```

```
Out[5]: b    1    0.204560
         3    0.567725
       c    1    0.595545
         2    0.964515
dtype: float64
```

```
In [6]: data.loc[["b", "c"]]
```

```
Out[6]: b 1 0.204560
         3 0.567725
         c 1 0.595545
         2 0.964515
dtype: float64
```

La selección es posible incluso desde un nivel "interior". Aquí seleccionoamos todos los valores que tienen el valor 2 del segundo nivel de índice:

```
In [7]: data.loc[:, 2]
```

```
Out[7]: a 0.316376
         c 0.964515
         d 0.653177
dtype: float64
```

## Ejemplo 3.1

```
In [8]: data_1 = {
    'Store': ['Store1', 'Store1', 'Store1', 'Store2', 'Store2', 'Store2'],
    'Product': ['A', 'A', 'B', 'A', 'B', 'B'],
    'Date': ['2024-07-01', '2024-07-02', '2024-07-01', '2024-07-01', '2024-07-02',
              'Sales': [100, 150, 200, 300, 400, 500]
}
df = pd.DataFrame(data_1)

df['Date'] = pd.to_datetime(df['Date']) # Convertir la columna 'Date' a tipo da
df
```

	<b>Store</b>	<b>Product</b>	<b>Date</b>	<b>Sales</b>
<b>0</b>	Store1	A	2024-07-01	100
<b>1</b>	Store1	A	2024-07-02	150
<b>2</b>	Store1	B	2024-07-01	200
<b>3</b>	Store2	A	2024-07-01	300
<b>4</b>	Store2	B	2024-07-02	400
<b>5</b>	Store2	B	2024-07-03	500

## Configurar a Multiindex

```
In [9]: df.set_index(['Store', 'Product', 'Date'], inplace=True)
df
```

Out[9]:

Sales			
Store	Product	Date	
Store1	A	2024-07-01	100
		2024-07-02	150
	B	2024-07-01	200
Store2	A	2024-07-01	300
	B	2024-07-02	400
		2024-07-03	500

La indexación jerárquica desempeña un papel importante en la reorganización de los datos y en las operaciones basadas en grupos, como la formación de una tabla dinámica. Por ejemplo, puede reorganizar estos datos en un DataFrame utilizando su método `unstack` ('desapilar'):

Volvamos al dataframe data

In [10]: `data`

```
Out[10]: a    1    0.929616
          2    0.316376
          3    0.183919
         b    1    0.204560
          3    0.567725
         c    1    0.595545
          2    0.964515
         d    2    0.653177
          3    0.748907
        dtype: float64
```

In [11]: `data.unstack()`

	1	2	3
a	0.929616	0.316376	0.183919
b	0.204560	NaN	0.567725
c	0.595545	0.964515	NaN
d	NaN	0.653177	0.748907

La operación inversa de desapilar (`unstack`) es apilar (`stack`):

In [12]: `data.unstack().stack()`

```
Out[12]: a 1 0.929616
          2 0.316376
          3 0.183919
         b 1 0.204560
          3 0.567725
         c 1 0.595545
          2 0.964515
         d 2 0.653177
          3 0.748907
        dtype: float64
```

## Vamos a desapilar el dataframe del ejemplo 3.1

```
In [13]: df
```

```
Out[13]:
```

Sales			
Store	Product	Date	
Store1	A	2024-07-01	100
		2024-07-02	150
	B	2024-07-01	200
Store2	A	2024-07-01	300
		2024-07-02	400
	B	2024-07-03	500

```
In [14]: df.unstack()
```

```
Out[14]:
```

		Sales			
		Date	2024-07-01	2024-07-02	2024-07-03
Store	Product				
Store1	A	1	100.0	150.0	NaN
	B	2	200.0	NaN	NaN
Store2	A	1	300.0	NaN	NaN
	B	2	NaN	400.0	500.0

```
In [15]: df.unstack('Store')
```

Out[15]:

Product	Date	Sales	
		Store	Store1
<b>A</b>	<b>2024-07-01</b>	100.0	300.0
	<b>2024-07-02</b>	150.0	NaN
<b>B</b>	<b>2024-07-01</b>	200.0	NaN
	<b>2024-07-02</b>	NaN	400.0
	<b>2024-07-03</b>	NaN	500.0

In [16]: df.unstack('Product')

Out[16]:

Product	Sales	
	A	B
Store	Date	
<b>Store1</b>	<b>2024-07-01</b>	100.0
	<b>2024-07-02</b>	150.0
<b>Store2</b>	<b>2024-07-01</b>	300.0
	<b>2024-07-02</b>	NaN
	<b>2024-07-03</b>	500.0

Con un DataFrame, cualquiera de los ejes puede tener un índice jerárquico:

In [17]: frame = pd.DataFrame(np.arange(12).reshape((4, 3)), index=[["a", "a", "b", "b"], [1, 2, 1, 2]], columns=[["Ohio", "Ohio", "Colorado"], ["Green", "Red", "Green"]])  
frame

Out[17]:

	Ohio Colorado		
	Green	Red	Green
<b>a</b>	1	0	1
	<b>2</b>	3	4
<b>b</b>	<b>1</b>	6	7
	<b>2</b>	9	10

Los niveles jerárquicos pueden tener nombres (como cadenas o cualquier objeto Python). Si es así, aparecerán en la salida de la consola:

```
In [18]: frame.index.names = ["key1", "key2"]
frame.columns.names = ["state", "color"]
frame
```

```
Out[18]:      state      Ohio  Colorado
              color  Green   Red     Green
key1  key2
a    1       0     1       2
      2       3     4       5
b    1       6     7       8
      2       9    10      11
```

Estos nombres sustituyen al atributo `name`, que sólo se utiliza con índices de un solo nivel. Puedes ver cuántos niveles tiene un índice accediendo a su atributo `nlevels`:

```
In [19]: frame.index.nlevels
```

```
Out[19]: 2
```

```
In [20]: frame.columns.nlevels
```

```
Out[20]: 2
```

Con la indexación parcial de columnas puede seleccionar grupos de columnas de forma similar:

```
In [21]: frame["Ohio"]
```

```
Out[21]:      color  Green   Red
key1  key2
a    1       0     1
      2       3     4
b    1       6     7
      2       9    10
```

Un `MultiIndex` puede crearse por sí mismo y luego reutilizarse; las columnas del DataFrame anterior con nombres de nivel también podrían crearse así:

```
In [22]: pd.MultiIndex.from_arrays([[["Ohio", "Ohio", "Colorado"],
                                  ["Green", "Red", "Green"]]],
                                  names=["state", "color"])
```

```
Out[22]: MultiIndex([(  'Ohio', 'Green'),
                      ('Ohio',  'Red'),
                      ('Colorado', 'Green')]),
                     names=['state', 'color'])
```

## Reordenación y clasificación de niveles

A veces puede ser necesario reorganizar el orden de los niveles en un eje u ordenar los datos por los valores de un nivel específico. El método `swaplevel` toma dos números o nombres de nivel y devuelve un nuevo objeto con los niveles intercambiados (pero los datos permanecen inalterados):

In [23]: `frame`

	<b>state</b>	<b>Ohio</b>	<b>Colorado</b>
	<b>color</b>	<b>Green</b>	<b>Red</b>
<b>key1</b>	<b>key2</b>		
<b>a</b>	<b>1</b>	0	1
	<b>2</b>	3	4
<b>b</b>	<b>1</b>	6	7
	<b>2</b>	9	10
			11

In [24]: `frame.swaplevel("key1", "key2")`

	<b>state</b>	<b>Ohio</b>	<b>Colorado</b>
	<b>color</b>	<b>Green</b>	<b>Red</b>
<b>key2</b>	<b>key1</b>		
<b>1</b>	<b>a</b>	0	1
<b>2</b>	<b>a</b>	3	4
<b>1</b>	<b>b</b>	6	7
<b>2</b>	<b>b</b>	9	10
			11

`sort_index` ordena por defecto los datos lexicográficamente utilizando todos los niveles del índice, pero puede elegir utilizar sólo un nivel o un subconjunto de niveles para ordenar pasando el argumento `level`. Por ejemplo:

In [25]: `frame.sort_index()`

Out[25]:

	state	Ohio	Colorado	
	color	Green	Red	Green
key1	key2			
<b>a</b>	<b>1</b>	0	1	2
	<b>2</b>	3	4	5
<b>b</b>	<b>1</b>	6	7	8
	<b>2</b>	9	10	11

In [26]: `frame.sort_index(level=0)`

Out[26]:

	state	Ohio	Colorado	
	color	Green	Red	Green
key1	key2			
<b>a</b>	<b>1</b>	0	1	2
	<b>2</b>	3	4	5
<b>b</b>	<b>1</b>	6	7	8
	<b>2</b>	9	10	11

In [27]: `frame.sort_index(level=1)`

Out[27]:

	state	Ohio	Colorado	
	color	Green	Red	Green
key1	key2			
<b>a</b>	<b>1</b>	0	1	2
	<b>2</b>	3	4	5
<b>b</b>	<b>1</b>	6	7	8
	<b>2</b>	9	10	11

In [28]: `frame.swaplevel(0, 1)`

Out[28]:

	state	Ohio	Colorado	
	color	Green	Red	Green
key2	key1			
1	a	0	1	2
2	a	3	4	5
1	b	6	7	8
2	b	9	10	11

In [29]:

```
frame.swaplevel(0, 1).sort_index(level=0)
#
```

Out[29]:

	state	Ohio	Colorado	
	color	Green	Red	Green
key2	key1			
1	a	0	1	2
	b	6	7	8
2	a	3	4	5
	b	9	10	11

El rendimiento de la selección de datos es mucho mejor en objetos indexados jerárquicamente si el índice está ordenado lexicográficamente comenzando por el nivel más externo, es decir, el resultado de llamar a `sort_index(level=0)` o `sort_index()`.

## Resumen estadístico por niveles

Muchas estadísticas descriptivas y de resumen en DataFrame y Series tienen una opción de nivel en la que puede especificar el nivel por el que desea agregar en un eje concreto. Considere el DataFrame anterior; podemos agregar por nivel en las filas o columnas, así:

In [30]:

```
frame.groupby(level="key2").sum()
```

Out[30]:

	state	Ohio	Colorado	
	color	Green	Red	Green
key2				
1		6	8	10
2		12	14	16

In [31]:

```
frame.groupby(level="color", axis="columns").sum()
```

```
C:\Users\juanj\AppData\Local\Temp\ipykernel_11984\775557097.py:1: FutureWarning:
DataFrame.groupby with axis=1 is deprecated. Do `frame.T.groupby(...)` without ax
is instead.
    frame.groupby(level="color", axis="columns").sum()
```

Out[31]:

	color	Green	Red
key1	key2		
<b>a</b>	<b>1</b>	2	1
	<b>2</b>	8	4
<b>b</b>	<b>1</b>	14	7
	<b>2</b>	20	10

## Indexación con las columnas de un DataFrame

No es inusual querer utilizar una o más columnas de un DataFrame como índice de fila; alternativamente, puede desear mover el índice de fila a las columnas del DataFrame. He aquí un ejemplo de DataFrame:

In [32]:

```
frame = pd.DataFrame({"a": range(7), "b": range(7, 0, -1),
                      "c": ["one", "one", "one", "two", "two",
                            "two", "two"],
                      "d": [0, 1, 2, 0, 1, 2, 3]})
```

Out[32]:

	a	b	c	d
<b>0</b>	0	7	one	0
<b>1</b>	1	6	one	1
<b>2</b>	2	5	one	2
<b>3</b>	3	4	two	0
<b>4</b>	4	3	two	1
<b>5</b>	5	2	two	2
<b>6</b>	6	1	two	3

La función `set_index` de DataFrame creará un nuevo DataFrame utilizando una o más de sus columnas como índice:

In [33]:

```
frame2 = frame.set_index(["c", "d"])
frame2
```

Out[33]:

	a	b
	c	d
<b>one</b>	0	0
	1	6
	2	5
<b>two</b>	0	3
	1	4
	2	5
	3	1

Por defecto, las columnas se eliminan del DataFrame, aunque puede dejarlas pasando `drop=False` a `set_index`:

In [34]: `frame.set_index(["c", "d"], drop=False)`

Out[34]:

	a	b	c	d
	c	d		
<b>one</b>	0	0	7	one 0
	1	1	6	one 1
	2	2	5	one 2
<b>two</b>	0	3	4	two 0
	1	4	3	two 1
	2	5	2	two 2
	3	6	1	two 3

`reset_index`, por otro lado, hace lo contrario que `set_index`; los niveles de índice jerárquico se mueven a las columnas:

In [35]: `frame2.reset_index()`

Out[35]:

	c	d	a	b
<b>0</b>	one	0	0	7
<b>1</b>	one	1	1	6
<b>2</b>	one	2	2	5
<b>3</b>	two	0	3	4
<b>4</b>	two	1	4	3
<b>5</b>	two	2	5	2
<b>6</b>	two	3	6	1

## 3.2 Combinar y fusionar conjuntos de datos

Los datos contenidos en los objetos pandas pueden combinarse de varias maneras:

`pandas.merge` : Conectar filas en DataFrames basándose en una o más claves. Esto resultará familiar a los usuarios de SQL u otras bases de datos relacionales, ya que implementa operaciones de unión de bases de datos.

`pandas.concat` : Concatena o "apila" objetos a lo largo de un eje.

`combine_first` : Empalma (Splice) datos superpuestos para llenar los valores que faltan en un objeto con valores de otro.

## Uniones de DataFrames al estilo de las bases de datos

Las operaciones de `Merge` o `join` combinan conjuntos de datos enlazando filas mediante una o varias claves. Estas operaciones son particularmente importantes en bases de datos relacionales (ejm SQL). La función `pandas.merge` en pandas es el principal punto de entrada para utilizar estos algoritmos en sus datos. Empecemos con un ejemplo sencillo:

```
In [36]: df1 = pd.DataFrame({"key": ["b", "b", "a", "c", "a", "a", "b"],  
                           "data1": pd.Series(range(7), dtype="Int64")})  
df1
```

Out[36]:

	key	data1
0	b	0
1	b	1
2	a	2
3	c	3
4	a	4
5	a	5
6	b	6

In [37]:

```
df2 = pd.DataFrame({"key": ["a", "b", "d"],
                    "data2": pd.Series(range(3), dtype="Int64")})
```

df2

Out[37]:

	key	data2
0	a	0
1	b	1
2	d	2

Este es un ejemplo de un join muchos-a-uno; los datos en df1 tienen múltiples filas etiquetadas como a y b, mientras que df2 tiene sólo una fila para cada valor en la columna clave. Llamando a `pandas.merge` con estos objetos, obtenemos:

In [38]:

```
pd.merge(df1, df2)
```

Out[38]:

	key	data1	data2
0	b	0	1
1	b	1	1
2	a	2	0
3	a	4	0
4	a	5	0
5	b	6	1

Nótese que no se ha especificado en qué columna unir. Si no se especifica esa información, `pandas.merge` utiliza los nombres de las columnas solapadas como claves. Sin embargo, es una buena práctica especificarlo explícitamente:

In [39]:

```
pd.merge(df1, df2, on="key")
```

Out[39]:

	key	data1	data2
0	b	0	1
1	b	1	1
2	a	2	0
3	a	4	0
4	a	5	0
5	b	6	1

En general, el orden de salida de las columnas en las operaciones `pandas.merge` no está especificado.

Si los nombres de las columnas son diferentes en cada objeto, puede especificarlos por separado:

```
In [40]: df3 = pd.DataFrame({"lkey": ["b", "b", "a", "c", "a", "a", "b"],  
                           "data1": pd.Series(range(7), dtype="Int64")})  
  
df3
```

Out[40]:

	lkey	data1
0	b	0
1	b	1
2	a	2
3	c	3
4	a	4
5	a	5
6	b	6

```
In [41]: df4 = pd.DataFrame({"rkey": ["a", "b", "d"],  
                           "data2": pd.Series(range(3), dtype="Int64")})  
  
df4
```

Out[41]:

	rkey	data2
0	a	0
1	b	1
2	d	2

```
In [42]: pd.merge(df3, df4, left_on="lkey", right_on="rkey")
```

	<b>lkey</b>	<b>data1</b>	<b>rkey</b>	<b>data2</b>
<b>0</b>	b	0	b	1
<b>1</b>	b	1	b	1
<b>2</b>	a	2	a	0
<b>3</b>	a	4	a	0
<b>4</b>	a	5	a	0
<b>5</b>	b	6	b	1

Puede notar que los valores "c" y "d" y los datos asociados faltan en el resultado. Por defecto, `pandas.merge` hace una unión "inner" (interna); las claves en el resultado son la intersección, o el conjunto común encontrado en ambas tablas. Otras opciones posibles son "left", "right" y "outer". La unión externa toma la unión de las claves, combinando el efecto de aplicar las uniones izquierda y derecha:

```
In [43]: pd.merge(df1, df2, how="outer")
```

	<b>key</b>	<b>data1</b>	<b>data2</b>
<b>0</b>	a	2	0
<b>1</b>	a	4	0
<b>2</b>	a	5	0
<b>3</b>	b	0	1
<b>4</b>	b	1	1
<b>5</b>	b	6	1
<b>6</b>	c	3	<NA>
<b>7</b>	d	<NA>	2

```
In [44]: pd.merge(df3, df4, left_on="lkey", right_on="rkey", how="outer")
```

	<b>lkey</b>	<b>data1</b>	<b>rkey</b>	<b>data2</b>
<b>0</b>	a	2	a	0
<b>1</b>	a	4	a	0
<b>2</b>	a	5	a	0
<b>3</b>	b	0	b	1
<b>4</b>	b	1	b	1
<b>5</b>	b	6	b	1
<b>6</b>	c	3	NaN	<NA>
<b>7</b>	NaN	<NA>	d	2

En una unión externa (outer join), las filas de los objetos DataFrame izquierdo o derecho que no coincidan en las claves del otro DataFrame aparecerán con valores NA en las columnas del otro DataFrame para las filas que no coincidan.

`how=inner` : Utiliza sólo las combinaciones de claves observadas en ambas tablas

`how="left"` : Utiliza todas las combinaciones de claves de la tabla de la izquierda

`how="right"` : Utiliza todas las combinaciones de claves de la tabla de la derecha

`how="outer"` : Utilizar conjuntamente todas las combinaciones de claves observadas en ambas tablas

Las fusiones (merges) de muchos a muchos forman el producto cartesiano de las claves coincidentes. He aquí un ejemplo:

```
In [45]: df1 = pd.DataFrame({"key": ["b", "b", "a", "c", "a", "b"],  
                           "data1": pd.Series(range(6), dtype="Int64")})  
  
df1
```

```
Out[45]:   key  data1  
0     b      0  
1     b      1  
2     a      2  
3     c      3  
4     a      4  
5     b      5
```

```
In [46]: df2 = pd.DataFrame({"key": ["a", "b", "a", "b", "d"],  
                           "data2": pd.Series(range(5), dtype="Int64")})  
  
df2
```

```
Out[46]:   key  data2  
0     a      0  
1     b      1  
2     a      2  
3     b      3  
4     d      4
```

```
In [47]: pd.merge(df1, df2, on="key", how="left")
```

Out[47]:

	key	data1	data2
0	b	0	1
1	b	0	3
2	b	1	1
3	b	1	3
4	a	2	0
5	a	2	2
6	c	3	<NA>
7	a	4	0
8	a	4	2
9	b	5	1
10	b	5	3

Como había tres filas "b" en el DataFrame izquierdo y dos en el derecho, hay seis filas "b" en el resultado. El método join pasado al argumento de la palabra clave `how` afecta sólo a los valores clave distintos que aparecen en el resultado:

In [48]: `pd.merge(df1, df2, how="inner")`

Out[48]:

	key	data1	data2
0	b	0	1
1	b	0	3
2	b	1	1
3	b	1	3
4	a	2	0
5	a	2	2
6	a	4	0
7	a	4	2
8	b	5	1
9	b	5	3

Para combinar (merge) con varias claves, pase una lista de nombres de columnas:

In [49]: `left = pd.DataFrame({"key1": ["foo", "foo", "bar"], "key2": ["one", "two", "one"], "lval": pd.Series([1, 2, 3], dtype='Int64')})`  
`left`

Out[49]:

	key1	key2	lval
0	foo	one	1
1	foo	two	2
2	bar	one	3

In [50]:

```
right = pd.DataFrame({"key1": ["foo", "foo", "bar", "bar"],
                      "key2": ["one", "one", "one", "two"],
                      "rval": pd.Series([4, 5, 6, 7], dtype='Int64')})
right
```

Out[50]:

	key1	key2	rval
0	foo	one	4
1	foo	one	5
2	bar	one	6
3	bar	two	7

In [51]:

```
pd.merge(left, right, on=["key1", "key2"], how="outer")
```

Out[51]:

	key1	key2	lval	rval
0	bar	one	3	6
1	bar	two	<NA>	7
2	foo	one	1	4
3	foo	one	1	5
4	foo	two	2	<NA>

Una última cuestión a tener en cuenta en las operaciones de fusión (merge) es el tratamiento de los nombres de columnas que se solapan. Por ejemplo:

In [52]:

```
pd.merge(left, right, on="key1")
```

Out[52]:

	key1	key2_x	lval	key2_y	rval
0	foo	one	1	one	4
1	foo	one	1	one	5
2	foo	two	2	one	4
3	foo	two	2	one	5
4	bar	one	3	one	6
5	bar	one	3	two	7

Mientras que puede tratar el solapamiento manualmente, `pandas.merge` tiene una opción de `suffixes` para especificar cadenas a añadir a los nombres solapados en los

objetos DataFrame izquierdo y derecho:

```
In [53]: pd.merge(left, right, on="key1", suffixes=("_left", "_right"))
```

	key1	key2_left	lval	key2_right	rval
0	foo	one	1	one	4
1	foo	one	1	one	5
2	foo	two	2	one	4
3	foo	two	2	one	5
4	bar	one	3	one	6
5	bar	one	3	two	7

## Repasso de los tipos básicos de Join

- Inner Join

Devuelve un DataFrame que contiene solo las filas donde hay una coincidencia en ambas tablas. Las filas no coincidentes se descartan.

**En pandas sería:**

```
result = pd.merge(df1, df2, how='inner', on='column_name')
```

`how='inner'` especifica el tipo de unión.

`on='column_name'` indica la columna en la que se basa la unión.

- Right join

Devuelve todas las filas del DataFrame de la derecha y las filas coincidentes del DataFrame de la izquierda. Si no hay coincidencia, las filas del DataFrame de la izquierda tendrán valores NaN.

**En pandas sería**

```
result = pd.merge(df1, df2, how='right', on='column_name')
```

- Left Join

Devuelve todas las filas del DataFrame de la izquierda y las filas coincidentes del DataFrame de la derecha. Si no hay coincidencia, las filas del DataFrame de la derecha tendrán valores NaN.

## En pandas sería

```
result = pd.merge(df1, df2, how='left', on='column_name')
```

- Outer Join = Left Join + Right Join

Devuelve todas las filas cuando hay una coincidencia en una de las tablas.  
Si no hay coincidencia, se utilizarán valores NaN para las filas faltantes.

## En pandas sería

```
result = pd.merge(df1, df2, how='outer', on='column_name')
```

### Ejemplo 3.2:

Partiendo de los siguientes DataFrames dados abajo, responder las 'preguntas de negocio'.

#### Dataframe 1: Información de clientes

```
In [54]: clientes = pd.DataFrame({
    'ClienteID': [1, 2, 3, 4, 5, 6],
    'Nombre': ['Ana', 'Luis', 'María', 'Carlos', 'Laura', 'Jorge'],
    'Edad': [34, 45, 23, 54, 31, 40],
    'Ciudad': ['Madrid', 'Barcelona', 'Madrid', 'Sevilla', 'Valencia', 'Bilbao'],
    'Email': ['ana@example.com', 'luis@example.com', 'maria@example.com',
              'carlos@example.com', 'laura@example.com', 'jorge@example.com'],
    'FechaRegistro': ['2020-01-01', '2020-06-15', '2021-03-20',
                      '2021-07-30', '2022-02-17', '2022-05-25']
})

print("DataFrame de Clientes:")
clientes
```

DataFrame de Clientes:

	<b>ClienteID</b>	<b>Nombre</b>	<b>Edad</b>	<b>Ciudad</b>	<b>Email</b>	<b>FechaRegistro</b>
<b>0</b>	1	Ana	34	Madrid	ana@example.com	2020-01-01
<b>1</b>	2	Luis	45	Barcelona	luis@example.com	2020-06-15
<b>2</b>	3	María	23	Madrid	maria@example.com	2021-03-20
<b>3</b>	4	Carlos	54	Sevilla	carlos@example.com	2021-07-30
<b>4</b>	5	Laura	31	Valencia	laura@example.com	2022-02-17
<b>5</b>	6	Jorge	40	Bilbao	jorge@example.com	2022-05-25

#### Dataframe 2: Información de contratos

```
In [55]: contratos = pd.DataFrame({
    'ContratoID': [101, 102, 103, 104, 105, 106, 107],
```

```

        'ClienteID': [1, 2, 2, 3, 5, 6, 7],
        'Tipo': ['Móvil', 'Internet', 'Televisión', 'Móvil', 'Internet', 'Televisión',
        'FechaInicio': ['2021-01-15', '2021-06-23', '2021-03-10',
                        '2021-08-05', '2021-12-12', '2021-07-19', '2022-01-10'],
        'DuraciónMeses': [24, 12, 12, 24, 12, 24, 12],
        'CostoMensual': [20, 40, 50, 25, 45, 55, 30]
    })

    print("DataFrame de Contratos:")
    contratos

```

DataFrame de Contratos:

	<b>ContratoID</b>	<b>ClienteID</b>	<b>Tipo</b>	<b>FechaInicio</b>	<b>DuraciónMeses</b>	<b>CostoMensual</b>
<b>0</b>	101	1	Móvil	2021-01-15	24	20
<b>1</b>	102	2	Internet	2021-06-23	12	40
<b>2</b>	103	2	Televisión	2021-03-10	12	50
<b>3</b>	104	3	Móvil	2021-08-05	24	25
<b>4</b>	105	5	Internet	2021-12-12	12	45
<b>5</b>	106	6	Televisión	2021-07-19	24	55
<b>6</b>	107	7	Móvil	2022-01-10	12	30

## Preguntas

**1- (Inner Join) ¿Cuáles son los detalles de contacto de los clientes que tienen contratos activos?**

```
In [56]: clientes_con_contratos = pd.merge(clientes, contratos, on='ClienteID', how='inner')
print("Detalles de contacto de clientes con contratos activos:")
print(clientes_con_contratos[['Nombre', 'Email', 'Tipo', 'FechaInicio']])
```

Detalles de contacto de clientes con contratos activos:

	Nombre	Email	Tipo	FechaInicio
0	Ana	ana@example.com	Móvil	2021-01-15
1	Luis	luis@example.com	Internet	2021-06-23
2	Luis	luis@example.com	Televisión	2021-03-10
3	Maria	maria@example.com	Móvil	2021-08-05
4	Laura	laura@example.com	Internet	2021-12-12
5	Jorge	jorge@example.com	Televisión	2021-07-19

**2- ¿Qué clientes se registraron antes de obtener un contrato?**

```
In [57]: clientes_con_contratos = pd.merge(clientes, contratos, on='ClienteID', how='inner')
clientes_anteriores_contrato = clientes_con_contratos[clientes_con_contratos['FechaRegistro'] < clientes_con_contratos['FechaInicio']]
print("Clientes que se registraron antes de obtener un contrato:")
print("#####")
print(clientes_anteriores_contrato[['Nombre', 'FechaRegistro', 'FechaInicio']])
```

Cientes que se registraron antes de obtener un contrato:

	Nombre	FechaRegistro	FechaInicio
0	Ana	2020-01-01	2021-01-15
1	Luis	2020-06-15	2021-06-23
2	Luis	2020-06-15	2021-03-10
3	Maria	2021-03-20	2021-08-05

### 3- ¿Qué clientes no tienen ningún contrato asociado y cuáles son sus detalles de contacto?

```
In [58]: clientes_sin_contratos = pd.merge(clientes, contratos, on='ClienteID', how='left'
clientes_sin_contratos = clientes_sin_contratos[clientes_sin_contratos['_merge']
# filtra el resultado de la unión para conservar
# solo las filas donde el valor en la columna _merge
# es left_only.

print("Clientes sin contratos asociados:")
print('#####
print(clientes_sin_contratos[['Nombre', 'Email', 'Ciudad']])
```

Cientes sin contratos asociados:

	Nombre	Email	Ciudad
4	Carlos	carlos@example.com	Sevilla

#### La línea:

- `clientes_sin_contratos =`  
`clientes_sin_contratos[clientes_sin_contratos['_merge'] ==`  
`'left_only']`

Significa que se seleccionan únicamente las filas que están presentes en el DataFrame de clientes pero no tienen correspondencia en el DataFrame de contratos.

El parámetro `indicator=True` agrega una columna extra llamada `_merge` al resultado de la unión. Esta columna indica el origen de cada fila en el resultado de la unión:

- `left_only` si la fila solo está presente en el DataFrame de la izquierda.
- `right_only` si la fila solo está presente en el DataFrame de la derecha.
- `both` si la fila está presente en ambos DataFrames.

### 4-¿Qué contratos no tienen un cliente asociado en la base de datos de clientes y cuáles son los detalles del contrato?

```
In [59]: contratos_sin_clientes = pd.merge(clientes, contratos, on='ClienteID', how='right'
contratos_sin_clientes = contratos_sin_clientes[contratos_sin_clientes['_merge']
# filtra el resultado de la unión para conservar
# solo las filas donde el valor en la columna _merge
# es right_only.

print("Contratos sin clientes asociados:")
```

```

print('#####')
print(contratos_sin_clientes[['ContratoID', 'Tipo', 'FechaInicio', 'CostoMensual']])

Contratos sin clientes asociados:
#####
    ContratoID  Tipo FechaInicio  CostoMensual
6           107  Móvil  2022-01-10          30

```

**La linea:**

- `contratos_sin_clientes = contratos_sin_clientes[contratos_sin_clientes['_merge'] == 'right_only']`

Esto significa que se seleccionan únicamente las filas que están presentes en el DataFrame de contratos pero no tienen correspondencia en el DataFrame de clientes.

### **5-Obtener una lista completa de todos los clientes y todos los contratos, independientemente de si tienen coincidencias en las otras tablas.**

```
In [60]: todos_clientes_contratos = pd.merge(clientes, contratos, on='ClienteID', how='outer')
print("Todos los clientes y contratos:")
print('#####')
print(todos_clientes_contratos)
```

Todos los clientes y contratos:

```
#####
  ClienteID  Nombre  Edad  Ciudad          Email FechaRegistro \
0           1     Ana  34.0  Madrid  ana@example.com  2020-01-01
1           2    Luis  45.0  Barcelona  luis@example.com  2020-06-15
2           2    Luis  45.0  Barcelona  luis@example.com  2020-06-15
3           3   María  23.0  Madrid  maria@example.com  2021-03-20
4           4   Carlos  54.0  Sevilla  carlos@example.com  2021-07-30
5           5   Laura  31.0  Valencia  laura@example.com  2022-02-17
6           6   Jorge  40.0   Bilbao  jorge@example.com  2022-05-25
7           7      NaN   NaN       NaN            NaN        NaN

  ContratoID      Tipo FechaInicio DuraciónMeses  CostoMensual  _merge
0     101.0    Móvil  2021-01-15       24.0       20.0    both
1     102.0  Internet  2021-06-23       12.0       40.0    both
2     103.0  Televisión  2021-03-10       12.0       50.0    both
3     104.0    Móvil  2021-08-05       24.0       25.0    both
4       NaN      NaN       NaN        NaN        NaN  left_only
5     105.0  Internet  2021-12-12       12.0       45.0    both
6     106.0  Televisión  2021-07-19       24.0       55.0    both
7     107.0    Móvil  2022-01-10       12.0       30.0  right_only
```

### **6- Cuáles son los clientes con contratos de más de 12 meses y cuáles son los detalles del contrato?**

```
In [61]: clientes_con_contratos_largos = pd.merge(clientes, contratos, on='ClienteID', how='inner')
clientes_con_contratos_largos = clientes_con_contratos_largos[clientes_con_contratos_largos['DuraciónMeses'] > 12]
print("Clientes con contratos de más de 12 meses:")
print(clientes_con_contratos_largos[['Nombre', 'Tipo', 'DuraciónMeses', 'CostoMensual']])
```

Clientes con contratos de más de 12 meses:

	Nombre	Tipo	DuraciónMeses	CostoMensual
0	Ana	Móvil	24	20
3	María	Móvil	24	25
5	Jorge	Televisión	24	55

## 7- ¿Qué clientes tienen contratos de un costo mensual superior a 40?

```
In [62]: clientes_con_contratos_caros = pd.merge(clientes, contratos, on='ClienteID', how='inner')
clientes_con_contratos_caros = clientes_con_contratos_caros[clientes_con_contratos_caros['CostoMensual'] > 40]
print("Clientes con contratos de un costo mensual superior a 40:")
print(clientes_con_contratos_caros[['Nombre', 'Tipo', 'CostoMensual']])
```

Clientes con contratos de un costo mensual superior a 40:

	Nombre	Tipo	CostoMensual
2	Luis	Televisión	50
4	Laura	Internet	45
5	Jorge	Televisión	55

Observar la siguiente tabla para una referencia de argumentos en `pandas.merge`. La siguiente sección cubre la unión (join) usando el índice de filas del DataFrame.

`left` : DataFrame a fusionar en el lado izquierdo.

`right` : DataFrame que se fusionará en el lado derecho.

`how` : Tipo de join a aplicar: "inner", "outer", "left", o "right"; por defecto es "inner".

`on` : Nombres de las columnas a unir (join). Deben encontrarse en ambos objetos DataFrame. Si no se especifica y no se dan otras claves de unión (join), se utilizará la intersección de los nombres de columna de la izquierda y la derecha como claves de join.

`left_on` : Columnas del DataFrame izquierdo (left) que se utilizarán como claves de unión (join). Puede ser un único nombre de columna o una lista de nombres de columna.

`right_on` : Análogo a `left_on` para DataFrame derecho(right).

`left_index` : Utiliza el índice de la fila de la izquierda como clave de unión(join) (o claves, si es un MultiIndex).

`right_index` : Análogo a `left_index`

`sort` : Ordena los datos fusionados lexicográficamente por las claves de unión (join); Falso por defecto.

`suffixes` : Tuple de valores de cadena para añadir a los nombres de columna en caso de solapamiento; por defecto ("\_x", "\_y") (por ejemplo, si "data" está en ambos objetos DataFrame, aparecerá como "data\_x" y "data\_y" en el resultado).

`copy` : Si es False, evita copiar datos en la estructura de datos resultante en algunos casos excepcionales; por defecto siempre copia.

`validate` : Verifica si la fusión (merge) es del tipo especificado, ya sea uno a uno, uno a muchos o muchos a muchos. Consulte el docstring para obtener más información sobre las opciones.

`indicator`: Añade una columna especial `_merge` que indica el origen de cada fila; los valores serán "left\_only", "right\_only" o "both" en función del origen de los datos unidos (joined) en cada fila.

## Merging en índice (Index)

En algunos casos, la(s) clave(s) de fusión(merging) de un DataFrame se encuentra(n) en su índice (etiquetas de fila). En este caso, puede pasar `left_index=True` o `right_index=True` (o ambos) para indicar que el índice debe utilizarse como clave de fusión:

```
In [63]: left1 = pd.DataFrame({"key": ["a", "b", "a", "a", "b", "c"],
                           "value": pd.Series(range(6), dtype="Int64")})
left1
```

```
Out[63]:   key  value
0     a      0
1     b      1
2     a      2
3     a      3
4     b      4
5     c      5
```

```
In [64]: right1 = pd.DataFrame({"group_val": [3.5, 7]}, index=["a", "b"])
right1
```

```
Out[64]:   group_val
a            3.5
b            7.0
```

```
In [65]: pd.merge(left1, right1, left_on="key", right_index=True)
```

```
Out[65]:   key  value  group_val
0     a      0        3.5
1     b      1        7.0
2     a      2        3.5
3     a      3        3.5
4     b      4        7.0
```

- `left_on="key"` significa que vamos a usar la columna `key` del DataFrame `left1` como la clave para la unión.

- `right_index=True` significa que vamos a usar el índice del DataFrame `right1` como la clave para la unión.

### Ejemplo 3.3

Supongamos que tenemos dos DataFrames: uno con información de ventas de dispositivos y otro con detalles de los dispositivos.

```
In [66]: # Dataframe ventas
ventas = pd.DataFrame({
    'VentaID': [1, 2, 3, 4, 5],
    'DispositivoID': [101, 102, 101, 103, 102],
    'Cantidad': [10, 5, 8, 7, 6]
})

# Dataframe dispositivos
dispositivos = pd.DataFrame({
    'NombreDispositivo': ['iPhone 13', 'Samsung Galaxy S21', 'Google Pixel 6'],
    'Precio': [799, 999, 599]
}, index=[101, 102, 103])

print("DataFrame de Ventas:")
ventas
```

DataFrame de Ventas:

```
Out[66]:   VentaID  DispositivoID  Cantidad
          0           101         10
          1           102         5
          2           101         8
          3           103         7
          4           102         6
```

```
In [67]: print("\nDataFrame de Dispositivos:")
print(dispositivos)
```

DataFrame de Dispositivos:

	NombreDispositivo	Precio
101	iPhone 13	799
102	Samsung Galaxy S21	999
103	Google Pixel 6	599

Ahora realizamos el merge "utilizando la columna `DispositivoID` del DataFrame izquierdo (`ventas`) como clave para la unión". Además se usará el índice del DataFrame derecho (`dispositivos`) como clave para la unión.

```
In [68]: # Realizar el merge
resultado = pd.merge(ventas, dispositivos, left_on='DispositivoID', right_index=True)

print("\nResultado del Merge:")
resultado
```

Resultado del Merge:

Out[68]:

	VentaID	DispositivoID	Cantidad	NombreDispositivo	Precio
0	1	101	10	iPhone 13	799
1	2	102	5	Samsung Galaxy S21	999
2	3	101	8	iPhone 13	799
3	4	103	7	Google Pixel 6	599
4	5	102	6	Samsung Galaxy S21	999

Dado que el método de fusión (merge) por defecto es intersecar las claves de unión (join), puede formar la unión de ellas con una unión (join) externa:

In [69]: `pd.merge(left1, right1, left_on="key", right_index=True, how="outer")`

Out[69]:

	key	value	group_val
0	a	0	3.5
2	a	2	3.5
3	a	3	3.5
1	b	1	7.0
4	b	4	7.0
5	c	5	NaN

Con datos indexados jerárquicamente, las cosas son más complicadas, ya que la unión (join) sobre índice equivale a una fusión (merge) de varias claves:

In [70]: `lefth = pd.DataFrame({"key1": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada"], "key2": [2000, 2001, 2002, 2001, 2002], "data": pd.Series(range(5), dtype="Int64")})  
lefth`

Out[70]:

	key1	key2	data
0	Ohio	2000	0
1	Ohio	2001	1
2	Ohio	2002	2
3	Nevada	2001	3
4	Nevada	2002	4

In [71]: `righth_index = pd.MultiIndex.from_arrays([["Nevada", "Nevada", "Ohio", "Ohio", "Ohio", "Ohio"], [2001, 2000, 2000, 2000, 2001, 2002]])`

```
# Es un índice jerárquico (MultiIndex) creado a partir de dos
# listas: la primera contiene nombres de estados y la segunda contiene años.
```

In [72]:

```
righth = pd.DataFrame({"event1": pd.Series([0, 2, 4, 6, 8, 10], dtype="Int64",
                                             index=righth_index),
                        "event2": pd.Series([1, 3, 5, 7, 9, 11], dtype="Int64",
                                             index=righth_index)})
```

righth

Out[72]:

		event1	event2
<b>Nevada</b>	<b>2001</b>	0	1
	<b>2000</b>	2	3
<b>Ohio</b>	<b>2000</b>	4	5
	<b>2000</b>	6	7
	<b>2001</b>	8	9
	<b>2002</b>	10	11

Los valores de event1 y event2 son series de números enteros con el índice jerárquico righth\_index.

In [73]:

```
pd.merge(left, righth, left_on=["key1", "key2"], right_index=True)
```

Out[73]:

	key1	key2	data	event1	event2
<b>0</b>	Ohio	2000	0	4	5
<b>0</b>	Ohio	2000	0	6	7
<b>1</b>	Ohio	2001	1	8	9
<b>2</b>	Ohio	2002	2	10	11
<b>3</b>	Nevada	2001	3	0	1

- `pd.merge` combina los DataFrames left y righth utilizando las columnas key1 y key2 de left como claves para la unión.
- `right_index=True` especifica que el índice jerárquico de righth se usará como clave para la unión.

Si se desea indicar varias columnas para hacer un merge, debe pasarlas en forma de lista (tenga en cuenta el tratamiento de los valores de índice duplicados con `how="outer"`):

In [74]:

```
pd.merge(left, righth, left_on=["key1", "key2"],
         right_index=True, how="outer")
```

Out[74]:

	key1	key2	data	event1	event2
4	Nevada	2000	<NA>	2	3
3	Nevada	2001	3	0	1
4	Nevada	2002	4	<NA>	<NA>
0	Ohio	2000	0	4	5
0	Ohio	2000	0	6	7
1	Ohio	2001	1	8	9
2	Ohio	2002	2	10	11

### Ejemplo 3.4

De vuelta a los dataframes:

In [75]:

```
# Dataframe ventas
ventas = pd.DataFrame({
    'Tienda': ['Tienda1', 'Tienda1', 'Tienda2', 'Tienda2', 'Tienda3'],
    'Modelo': ['iPhone 13', 'Samsung S21', 'iPhone 13', 'Google Pixel 6', 'Samsung S21'],
    'Capacidad': ['64GB', '128GB', '128GB', '128GB', '256GB'], # Nueva columna
    'Fecha': ['2023-01-01', '2023-01-02', '2023-01-01', '2023-01-03', '2023-01-04'],
    'Cantidad': [5, 3, 2, 4, 1]
})
# Dataframe detalles
detalles_index = pd.MultiIndex.from_arrays([
    [
        ['iPhone 13', 'Samsung S21', 'Google Pixel 6', 'iPhone 13', 'Samsung S21'],
        ['64GB', '128GB', '128GB', '128GB', '256GB']
    ], names=['Modelo', 'Capacidad']
])

# Crear DataFrame de Detalles
detalles = pd.DataFrame({
    'Precio': [799, 999, 699, 899, 1099],
    'Color': ['Negro', 'Blanco', 'Negro', 'Blanco', 'Azul']
}, index=detalles_index)

print("DataFrame de Ventas:")
ventas
```

DataFrame de Ventas:

Out[75]:

	Tienda	Modelo	Capacidad	Fecha	Cantidad
0	Tienda1	iPhone 13	64GB	2023-01-01	5
1	Tienda1	Samsung S21	128GB	2023-01-02	3
2	Tienda2	iPhone 13	128GB	2023-01-01	2
3	Tienda2	Google Pixel 6	128GB	2023-01-03	4
4	Tienda3	Samsung S21	256GB	2023-01-04	1

```
In [76]: print("\nDataFrame de Detalles:")
detalles
```

DataFrame de Detalles:

		Precio	Color
Modelo	Capacidad		
iPhone 13	64GB	799	Negro
Samsung S21	128GB	999	Blanco
Google Pixel 6	128GB	699	Negro
iPhone 13	128GB	899	Blanco
Samsung S21	256GB	1099	Azul

Se pide combinar el dataframe `ventas` con el dataframe `detalles`. En este caso se usará la columna `Modelo` de la dataframe `ventas`, además se usará el dataframe `detalles` para la creación de índices jerárquicos.

```
In [77]: # Realizar el merge
resultado = pd.merge(ventas, detalles, left_on=['Modelo', 'Capacidad'], right_index=True)
print("\nResultado del Merge:")
resultado
```

Resultado del Merge:

	Tienda	Modelo	Capacidad	Fecha	Cantidad	Precio	Color
0	Tienda1	iPhone 13	64GB	2023-01-01	5	799	Negro
1	Tienda1	Samsung S21	128GB	2023-01-02	3	999	Blanco
2	Tienda2	iPhone 13	128GB	2023-01-01	2	899	Blanco
3	Tienda2	Google Pixel 6	128GB	2023-01-03	4	699	Negro
4	Tienda3	Samsung S21	256GB	2023-01-04	1	1099	Azul

- `left_on=['Modelo', 'Capacidad']:`

Este parámetro especifica que se deben usar las columnas `Modelo` y `Capacidad` del DataFrame `ventas` como las claves para la unión.

- `right_index=True:`

Indica que el índice del DataFrame derecho (`detalles`) se utilizará como la clave para la unión. `detalles` tiene un índice jerárquico (MultiIndex) compuesto por `Modelo` y `Capacidad`.

## Merge con todos los índices

También es posible utilizar los índices de ambos lados del merge:

```
In [95]: left2 = pd.DataFrame([[1., 2.], [3., 4.], [5., 6.]],
                           index=["a", "c", "e"],
                           columns=["Ohio", "Nevada"]).astype("Int64")
left2
```

Out[95]:

	Ohio	Nevada
a	1	2
c	3	4
e	5	6

```
In [96]: right2 = pd.DataFrame([[7., 8.], [9., 10.], [11., 12.], [13., 14.]],
                             index=["b", "c", "d", "e"],
                             columns=["Missouri", "Alabama"]).astype("Int64")
right2
```

Out[96]:

	Missouri	Alabama
b	7	8
c	9	10
d	11	12
e	13	14

```
In [97]: pd.merge(left2, right2, how="outer", left_index=True, right_index=True)
```

Out[97]:

	Ohio	Nevada	Missouri	Alabama
a	1	2	<NA>	<NA>
b	<NA>	<NA>	7	8
c	3	4	9	10
d	<NA>	<NA>	11	12
e	5	6	13	14

## Uso de Join en Pandas

En `pandas.DataFrame` tambien hay un método de instancia `join` para simplificar la combinación por índice. También se puede utilizar para combinar varios objetos `DataFrame` que tengan índices iguales o similares pero columnas que no se solapen. En el ejemplo anterior, podríamos haber escrito:

```
In [81]: left2.join(right2, how="outer")
```

Out[81]:

	Ohio	Nevada	Missouri	Alabama
a	1	2	<NA>	<NA>
b	<NA>	<NA>	7	8
c	3	4	9	10
d	<NA>	<NA>	11	12
e	5	6	13	14

Comparado con `pandas.merge`, el método `join` de DataFrame realiza una unión a la izquierda (left) en las claves de unión por defecto. También soporta unir el índice del DataFrame pasado en una de las columnas del DataFrame al que se está llamando:

In [99]:

`left1.join(right1, on="key")`

Out[99]:

	key	value	group_val
0	a	0	3.5
1	b	1	7.0
2	a	2	3.5
3	a	3	3.5
4	b	4	7.0
5	c	5	NaN

Puede pensar en este método como una unión de datos "dentro" del objeto cuyo método `join` fue llamado.

Por último, para simples fusiones (merge) índice sobre índice, puede pasar una lista de DataFrames a unir como alternativa al uso de la función más general `pandas.concat` descrita en la siguiente sección:

In [100...]

```
another = pd.DataFrame([[7., 8.], [9., 10.], [11., 12.], [16., 17.]],
                      index=["a", "c", "e", "f"],
                      columns=["New York", "Oregon"])
another
```

Out[100...]

	New York	Oregon
a	7.0	8.0
c	9.0	10.0
e	11.0	12.0
f	16.0	17.0

Repasemos que tienen `left2` y `right2`

In [101...]

`right2`

Out[101...]

**Missouri Alabama**

<b>b</b>	7	8
<b>c</b>	9	10
<b>d</b>	11	12
<b>e</b>	13	14

In [102...]

left2

Out[102...]

**Ohio Nevada**

<b>a</b>	1	2
<b>c</b>	3	4
<b>e</b>	5	6

In [84]: left2.join([right2, another])

Out[84]:

**Ohio Nevada Missouri Alabama New York Oregon**

<b>a</b>	1	2	<NA>	<NA>	7.0	8.0
<b>c</b>	3	4	9	10	9.0	10.0
<b>e</b>	5	6	13	14	11.0	12.0

In [103...]

left2.join([right2, another], how="outer")

Out[103...]

**Ohio Nevada Missouri Alabama New York Oregon**

<b>a</b>	1	2	<NA>	<NA>	7.0	8.0
<b>c</b>	3	4	9	10	9.0	10.0
<b>e</b>	5	6	13	14	11.0	12.0
<b>b</b>	<NA>	<NA>	7	8	NaN	NaN
<b>d</b>	<NA>	<NA>	11	12	NaN	NaN
<b>f</b>	<NA>	<NA>	<NA>	<NA>	16.0	17.0

## Concatenar a lo largo de un eje

Otro tipo de operación de combinación de datos se denomina indistintamente concatenación o apilamiento (stacking). La función concatenate de NumPy puede hacer esto con matrices NumPy:

In [86]: arr = np.arange(12).reshape((3, 4))  
arr

```
Out[86]: array([[ 0,  1,  2,  3],
   [ 4,  5,  6,  7],
   [ 8,  9, 10, 11]])
```

```
In [87]: np.concatenate([arr, arr], axis=1)
```

```
Out[87]: array([[ 0,  1,  2,  3,  0,  1,  2,  3],
   [ 4,  5,  6,  7,  4,  5,  6,  7],
   [ 8,  9, 10, 11,  8,  9, 10, 11]])
```

En el contexto de objetos pandas como Series y DataFrame, tener ejes etiquetados permite generalizar aún más la concatenación de arrays. En particular, usted tiene un número de preocupaciones adicionales:

- Si los objetos están indexados de forma diferente en los otros ejes, ¿debemos combinar los elementos distintos en estos ejes o utilizar sólo los valores en común?
- ¿Es necesario que los trozos (chunk) de datos concatenados sean identificables como tales en el objeto resultante?
- ¿Contiene el "eje de concatenación" datos que deban conservarse? En muchos casos, es mejor descartar las etiquetas enteras por defecto de un DataFrame durante la concatenación.

La función `concat` en pandas proporciona una forma consistente de abordar cada una de estas cuestiones. Daré una serie de ejemplos para ilustrar cómo funciona.

Supongamos que tenemos tres Series sin solapamiento de índices (index overlap):

```
In [61]: s1 = pd.Series([0, 1], index=["a", "b"], dtype="Int64")
s2 = pd.Series([2, 3, 4], index=["c", "d", "e"], dtype="Int64")
s3 = pd.Series([5, 6], index=["f", "g"], dtype="Int64")
```

Al llamar a `pandas.concat` con estos objetos en una lista se pegan los valores y los índices:

```
In [62]: s1
```

```
Out[62]: a    0
         b    1
         dtype: Int64
```

```
In [63]: s2
```

```
Out[63]: c    2
         d    3
         e    4
         dtype: Int64
```

```
In [64]: s3
```

```
Out[64]: f    5
         g    6
         dtype: Int64
```

```
In [65]: pd.concat([s1, s2, s3])
```

```
Out[65]: a    0
         b    1
         c    2
         d    3
         e    4
         f    5
         g    6
        dtype: Int64
```

Por defecto, `pandas.concat` funciona con `axis="index"`, produciendo otra Serie. Si pasa `axis="columns"`, el resultado será un DataFrame:

```
In [66]: pd.concat([s1, s2, s3], axis="columns")
```

```
Out[66]:      0    1    2
a    0  <NA>  <NA>
b    1  <NA>  <NA>
c  <NA>    2  <NA>
d  <NA>    3  <NA>
e  <NA>    4  <NA>
f  <NA>  <NA>    5
g  <NA>  <NA>    6
```

En este caso no hay solapamiento en el otro eje, que como puede ver es la unión (el join "externo") de los índices. En su lugar, puede intersecarlos pasando `join="inner"`:

```
In [67]: s4 = pd.concat([s1, s3])
s4
```

```
Out[67]: a    0
         b    1
         f    5
         g    6
        dtype: Int64
```

```
In [68]: pd.concat([s1, s4], axis="columns")
```

```
Out[68]:      0    1
a    0  0
b    1  1
f  <NA>  5
g  <NA>  6
```

```
In [69]: pd.concat([s1, s4], axis="columns", join="inner")
```

```
Out[69]:   0  1
          a  0  0
          b  1  1
```

En este último ejemplo, las etiquetas "f" y "g" han desaparecido debido a la opción `join="inner"`.

Un problema potencial es que las piezas concatenadas no son identificables en el resultado. Supongamos, en cambio, que desea crear un índice jerárquico en el eje de concatenación. Para ello, utilice el argumento `keys`:

```
In [70]: result = pd.concat([s1, s1, s3], keys=["one", "two", "three"])
result
```

```
Out[70]:   one    a    0
           b    1
          two    a    0
           b    1
         three    f    5
           g    6
dtype: Int64
```

```
In [71]: result.unstack()
```

```
Out[71]:      a    b    f    g
one      0    1  <NA>  <NA>
two      0    1  <NA>  <NA>
three  <NA> <NA>    5    6
```

En el caso de combinar Series a lo largo de `axis="columns"`, las claves se convierten en las cabeceras de las columnas del DataFrame:

```
In [72]: pd.concat([s1, s2, s3], axis="columns", keys=["one", "two", "three"])
```

```
Out[72]:   one  two  three
a      0  <NA>  <NA>
b      1  <NA>  <NA>
c    <NA>    2  <NA>
d    <NA>    3  <NA>
e    <NA>    4  <NA>
f    <NA>  <NA>    5
g    <NA>  <NA>    6
```

La misma lógica se extiende a los objetos DataFrame:

```
In [73]: df1 = pd.DataFrame(np.arange(6).reshape(3, 2), index=["a", "b", "c"],
                           columns=["one", "two"])
df1
```

Out[73]:

	one	two
<b>a</b>	0	1
<b>b</b>	2	3
<b>c</b>	4	5

```
In [74]: df2 = pd.DataFrame(5 + np.arange(4).reshape(2, 2), index=["a", "c"],
                           columns=["three", "four"])
df2
```

Out[74]:

	three	four
<b>a</b>	5	6
<b>c</b>	7	8

```
In [75]: pd.concat([df1, df2], axis="columns", keys=["level1", "level2"])
```

Out[75]:

	level1	level2		
	one	two	three	four
<b>a</b>	0	1	5.0	6.0
<b>b</b>	2	3	NaN	NaN
<b>c</b>	4	5	7.0	8.0

Aquí el argumento keys se utiliza para crear un índice jerárquico donde el primer nivel puede utilizarse para identificar cada uno de los objetos DataFrame concatenados.

Si pasa un diccionario de objetos en lugar de una lista, se utilizarán las claves del diccionario para la opción keys:

```
In [76]: pd.concat({"level1": df1, "level2": df2}, axis="columns")
```

Out[76]:

	level1	level2		
	one	two	three	four
<b>a</b>	0	1	5.0	6.0
<b>b</b>	2	3	NaN	NaN
<b>c</b>	4	5	7.0	8.0

Existen argumentos adicionales que regulan cómo se crea el índice jerárquico, ver tabla:

### Argumento | Descripción

`objs` : Lista o diccionario de objetos pandas a concatenar; este es el único argumento requerido.

`axis` : Eje sobre el que concatenar; por defecto se concatena por filas (`axis="index"`)

`join` : Ya sea "interior" o "exterior" ("exterior" por defecto); si intersecar (interior) o unir (exterior) índices a lo largo de los otros ejes.

`keys` : Valores que se asocian a los objetos que se concatenan, formando un índice jerárquico a lo largo del eje de concatenación; puede ser una lista o array de valores arbitrarios, un array de tuplas o una lista de arrays (si se pasan arrays de varios niveles en niveles).

`levels` : Índices específicos que se utilizarán como nivel o niveles de índice jerárquico si se pasan claves.

`names` : Nombres de los niveles jerárquicos creados si se pasan claves y/o niveles

`verify_integrity` : Comprueba si hay duplicados en el nuevo eje del objeto concatenado y lanza una excepción si es así; por defecto (`False`) permite duplicados.

`ignore_index` : No preservar los índices a lo largo del eje de concatenación, en su lugar producir un nuevo índice `range(total_length)`

Por ejemplo, podemos nombrar los niveles de eje creados con el argumento `names` :

```
In [77]: import pandas as pd
pd.concat([df1, df2], axis="columns", keys=["level1", "level2"],
          names=["upper", "lower"])
```

```
Out[77]: upper      level1      level2
           lower   one   two   three   four
a            0     1    5.0    6.0
b            2     3    NaN    NaN
c            4     5    7.0    8.0
```

Una última consideración se refiere a los DataFrames en los que el índice de fila no contiene ningún dato relevante:

```
In [78]: df1 = pd.DataFrame(np.random.standard_normal((3, 4)),
                        columns=["a", "b", "c", "d"])
df1
```

```
Out[78]:      a        b        c        d
0  1.248804  0.774191 -0.319657 -0.624964
1  1.078814  0.544647  0.855588  1.343268
2 -0.267175  1.793095 -0.652929 -1.886837
```

```
In [79]: df2 = pd.DataFrame(np.random.standard_normal((2, 3)),
                           columns=["b", "d", "a"])
df2
```

```
Out[79]:      b      d      a
0  1.059626  0.644448 -0.007799
1 -0.449204  2.448963  0.667226
```

En este caso, puede pasar `ignore_index=True`, que descarta los índices de cada DataFrame y concatena los datos sólo en las columnas, asignando un nuevo índice por defecto:

```
In [80]: pd.concat([df1, df2], ignore_index=True)
```

```
Out[80]:      a      b      c      d
0  1.248804  0.774191 -0.319657 -0.624964
1  1.078814  0.544647  0.855588  1.343268
2 -0.267175  1.793095 -0.652929 -1.886837
3 -0.007799  1.059626       NaN  0.644448
4  0.667226 -0.449204       NaN  2.448963
```

## Combinación de datos con solapamiento

Existe otra situación de combinación de datos que no puede expresarse como una operación de fusión (merge) o concatenación. Puede tener dos conjuntos de datos con índices que se solapan total o parcialmente. Como ejemplo, considere la función `where` de NumPy, que realiza el equivalente orientado en arrays de una expresión if-else:

```
In [81]: a = pd.Series([np.nan, 2.5, 0.0, 3.5, 4.5, np.nan],
                  index=["f", "e", "d", "c", "b", "a"])
a
```

```
Out[81]: f      NaN
         e      2.5
         d      0.0
         c      3.5
         b      4.5
         a      NaN
dtype: float64
```

```
In [82]: b = pd.Series([0., np.nan, 2., np.nan, np.nan, 5.],
                  index=["a", "b", "c", "d", "e", "f"])
b
```

```
Out[82]: a    0.0
         b    NaN
         c    2.0
         d    NaN
         e    NaN
         f    5.0
        dtype: float64
```

```
In [83]: np.where(pd.isna(a), b, a)
```

```
Out[83]: array([0. , 2.5, 0. , 3.5, 4.5, 5. ])
```

Aquí, siempre que los valores en a sean nulos, se seleccionan los valores de b, de lo contrario se seleccionan los valores no nulos de a. El uso de `numpy.where` no comprueba si las etiquetas de índice están alineadas o no (y ni siquiera requiere que los objetos tengan la misma longitud), así que si quieras alinear valores por índice, utiliza el método `combine_first` de la serie:

```
In [84]: a.combine_first(b)
```

```
Out[84]: a    0.0
         b    4.5
         c    3.5
         d    0.0
         e    2.5
         f    5.0
        dtype: float64
```

Con DataFrames, `combine_first` hace lo mismo columna por columna, por lo que se puede pensar en ello como "parchear" (patching) los datos que faltan en el objeto de llamada con los datos del objeto que se pasa:

```
In [85]: df1 = pd.DataFrame({"a": [1., np.nan, 5., np.nan],
                           "b": [np.nan, 2., np.nan, 6.],
                           "c": range(2, 18, 4)})
df1
```

```
Out[85]:      a    b    c
0    1.0  NaN   2
1    NaN   2.0   6
2    5.0  NaN  10
3    NaN   6.0  14
```

```
In [86]: df2 = pd.DataFrame({"a": [5., 4., np.nan, 3., 7.],
                           "b": [np.nan, 3., 4., 6., 8.]})
df2
```

Out[86]:

	<b>a</b>	<b>b</b>
<b>0</b>	5.0	NaN
<b>1</b>	4.0	3.0
<b>2</b>	NaN	4.0
<b>3</b>	3.0	6.0
<b>4</b>	7.0	8.0

In [87]: `df1.combine_first(df2)`

Out[87]:

	<b>a</b>	<b>b</b>	<b>c</b>
<b>0</b>	1.0	NaN	2.0
<b>1</b>	4.0	2.0	6.0
<b>2</b>	5.0	4.0	10.0
<b>3</b>	3.0	6.0	14.0
<b>4</b>	7.0	8.0	NaN

La salida de `combine_first` con objetos DataFrame tendrá la unión de todos los nombres de columna.

### 3.3 Remodelar (Reshaping) y pivotar (Pivoting)

Existen varias operaciones básicas para reorganizar datos tabulares. Se denominan operaciones de `reshape` o `pivot`.

#### Remodelación (Reshaping) con indexación jerárquica

La indexación jerárquica proporciona una forma coherente de reorganizar los datos en un DataFrame. Existen dos acciones principales:

`stack` : Esto "gira" o pivota de las columnas de los datos a las filas.

`unstack` : Pivota de las filas a las columnas.

Se ilustrarán estas operaciones con una serie de ejemplos. Consideremos un pequeño DataFrame con arrays de cadenas como índices de fila y columna:

In [88]:

```
data = pd.DataFrame(np.arange(6).reshape((2, 3)),
                    index=pd.Index(["Ohio", "Colorado"], name="state"),
                    columns=pd.Index(["one", "two", "three"],
                                   name="number"))
```

data

Out[88]: `number one two three`

state			
Ohio	0	1	2
Colorado	3	4	5

Utilizando el método `stack` en estos datos, las columnas pivotan en las filas, produciendo una Serie:

In [89]: `result = data.stack()  
result`

Out[89]: `state number  
Ohio one 0  
 two 1  
 three 2  
Colorado one 3  
 two 4  
 three 5  
dtype: int32`

A partir de una Serie indexada jerárquicamente, puede reorganizar los datos de nuevo en un DataFrame con `unstack`:

In [90]: `result.unstack()`

Out[90]: `number one two three`

state			
Ohio	0	1	2
Colorado	3	4	5

Por defecto, el nivel más interno está desapilado (igual que la pila). Puedes desapilar(`unstack`) un nivel diferente pasando un número o nombre de nivel:

In [91]: `result.unstack(level=0)`

Out[91]: `state Ohio Colorado`

number		
one	0	3
two	1	4
three	2	5

In [92]: `result.unstack(level="state")`

Out[92]: state Ohio Colorado

	number	
one	0	3
two	1	4
three	2	5

El desapilamiento puede introducir datos que faltan si no se encuentran todos los valores del nivel en cada subgrupo:

```
In [93]: s1 = pd.Series([0, 1, 2, 3], index=["a", "b", "c", "d"], dtype="Int64")
s1
```

```
Out[93]: a    0
         b    1
         c    2
         d    3
dtype: Int64
```

```
In [94]: s2 = pd.Series([4, 5, 6], index=["c", "d", "e"], dtype="Int64")
s2
```

```
Out[94]: c    4
         d    5
         e    6
dtype: Int64
```

```
In [95]: data2 = pd.concat([s1, s2], keys=["one", "two"])
data2
```

```
Out[95]: one   a    0
          b    1
          c    2
          d    3
        two   c    4
          d    5
          e    6
dtype: Int64
```

El apilamiento (Stacking) filtra por defecto los datos que faltan, por lo que la operación es más fácilmente invertible:

```
In [96]: data2.unstack()
```

```
Out[96]:      a   b   c   d   e
one     0   1   2   3  <NA>
two   <NA> <NA>  4   5   6
```

```
In [97]: data2.unstack().stack()
```

```
Out[97]:   one    a    0
            b    1
            c    2
            d    3
       two    c    4
            d    5
            e    6
dtype: Int64
```

```
In [98]: data2.unstack().stack(dropna=False)
```

```
Out[98]:   one    a    0
            b    1
            c    2
            d    3
            e    <NA>
       two    a    <NA>
            b    <NA>
            c    4
            d    5
            e    6
dtype: Int64
```

Cuando se desapila (unstack) en un DataFrame, el nivel desapilado se convierte en el nivel más bajo del resultado:

```
In [99]: df = pd.DataFrame({"left": result, "right": result + 5},
                           columns=pd.Index(["left", "right"], name="side"))
df
```

	side	left	right
state	number		
<b>Ohio</b>	<b>one</b>	0	5
	<b>two</b>	1	6
	<b>three</b>	2	7
<b>Colorado</b>	<b>one</b>	3	8
	<b>two</b>	4	9
	<b>three</b>	5	10

```
In [100...]: df.unstack(level="state")
```

	side	left	right	
state	Ohio	Colorado	Ohio	Colorado
number				
<b>one</b>	0	3	5	8
<b>two</b>	1	4	6	9
<b>three</b>	2	5	7	10

Al igual que con `unstack`, al llamar a `stack` podemos indicar el nombre del eje a apilar:

```
In [101... df.unstack(level="state").stack(level="side")
```

```
Out[101...      state  Ohio  Colorado
```

number	side		
one	left	0	3
	right	5	8
two	left	1	4
	right	6	9
three	left	2	5
	right	7	10

## Pasar del formato "largo" (Long) al "ancho (Wide)

Una forma habitual de almacenar múltiples series temporales en bases de datos y archivos CSV es lo que a veces se denomina formato largo o apilado (stacked format). En este formato, los valores individuales se representan mediante una única fila en una tabla, en lugar de múltiples valores por fila.

Carguemos algunos datos de ejemplo y hagamos una pequeña limpieza de series temporales y otros datos:

```
In [102... data = pd.read_csv("macrodata.csv")
```

```
In [103... data = data.loc[:, ["year", "quarter", "realgdp", "infl", "unemp"]]
```

```
In [104... data.head()
```

```
Out[104...      year  quarter  realgdp  infl  unemp
```

<b>0</b>	1959	1	2710.349	0.00	5.8
<b>1</b>	1959	2	2778.801	2.34	5.1
<b>2</b>	1959	3	2775.488	2.74	5.3
<b>3</b>	1959	4	2785.204	0.27	5.6
<b>4</b>	1960	1	2847.699	2.31	5.2

En primer lugar, se ha utilizado `pandas.PeriodIndex` (que representa intervalos de tiempo en lugar de puntos en el tiempo), lo veremos con más detalle en el tema de Series temporales, para combinar las columnas de `year` y `quarter` y establecer el índice para que consista en valores `datetime` al final de cada trimestre:

```
In [105...]: periods = pd.PeriodIndex(year=data.pop("year"),
                                quarter=data.pop("quarter"),
                                name="date")
periods
```

```
Out[105...]: PeriodIndex(['1959Q1', '1959Q2', '1959Q3', '1959Q4', '1960Q1', '1960Q2',
                           '1960Q3', '1960Q4', '1961Q1', '1961Q2',
                           ...
                           '2007Q2', '2007Q3', '2007Q4', '2008Q1', '2008Q2', '2008Q3',
                           '2008Q4', '2009Q1', '2009Q2', '2009Q3'],
                          dtype='period[Q-DEC]', name='date', length=203)
```

```
In [106...]: data.index = periods.to_timestamp("D")
data.head()
```

```
Out[106...]:      realgdp  infl  unemp
date
1959-01-01  2710.349  0.00    5.8
1959-04-01  2778.801  2.34    5.1
1959-07-01  2775.488  2.74    5.3
1959-10-01  2785.204  0.27    5.6
1960-01-01  2847.699  2.31    5.2
```

Aquí se ha utilizado el método `pop` en el DataFrame, que devuelve una columna al mismo tiempo que la elimina del DataFrame.

A continuación, se selecciona un subconjunto de columnas y se le da el nombre `"item"` al índice de columnas:

```
In [107...]: data = data.reindex(columns=["realgdp", "infl", "unemp"])
data.columns.name = "item"
data.head()
```

```
Out[107...]:      item  realgdp  infl  unemp
date
1959-01-01  2710.349  0.00    5.8
1959-04-01  2778.801  2.34    5.1
1959-07-01  2775.488  2.74    5.3
1959-10-01  2785.204  0.27    5.6
1960-01-01  2847.699  2.31    5.2
```

Por último, se ha hecho un reshape con `stack`, convierte los nuevos niveles de índice en columnas con `reset_index` y, por último, se le da el nombre `"value"` a la columna que contiene los valores de los datos:

```
In [108...]: long_data = (data.stack()
                      .reset_index()
                      .rename(columns={0: "value"}))
```

Ahora, `ldata` se ve así:

```
In [109...]: long_data[:10]
```

	<b>date</b>	<b>item</b>	<b>value</b>
<b>0</b>	1959-01-01	realgdp	2710.349
<b>1</b>	1959-01-01	infl	0.000
<b>2</b>	1959-01-01	unemp	5.800
<b>3</b>	1959-04-01	realgdp	2778.801
<b>4</b>	1959-04-01	infl	2.340
<b>5</b>	1959-04-01	unemp	5.100
<b>6</b>	1959-07-01	realgdp	2775.488
<b>7</b>	1959-07-01	infl	2.740
<b>8</b>	1959-07-01	unemp	5.300
<b>9</b>	1959-10-01	realgdp	2785.204

En este formato denominado largo para series temporales múltiples, cada fila de la tabla representa una única observación.

Los datos se almacenan con frecuencia de esta forma en bases de datos relacionales SQL, ya que un esquema fijo (nombres de columna y tipos de datos) permite que el número de valores distintos en la columna de `ítem` cambie a medida que se añaden datos a la tabla.

En el ejemplo anterior, `date` y `ítem` suelen ser las claves primarias (en el lenguaje de las bases de datos relacionales), lo que ofrece integridad relacional y facilita las uniones (joins). En algunos casos, puede ser más difícil trabajar con los datos en este formato; es posible que prefiera tener un DataFrame que contenga una columna por cada valor de elemento distinto indexado por marcas de tiempo (timestamps) en la columna de fecha(date). El método `pivot` de DataFrame realiza exactamente esta transformación:

```
In [110...]: pivoted = long_data.pivot(index="date", columns="ítem",
                                values="value")
pivoted.head()
```

Out[110...]

	item	infl	realgdp	unemp
				<b>date</b>

<b>1959-01-01</b>	0.00	2710.349	5.8	
<b>1959-04-01</b>	2.34	2778.801	5.1	
<b>1959-07-01</b>	2.74	2775.488	5.3	
<b>1959-10-01</b>	0.27	2785.204	5.6	
<b>1960-01-01</b>	2.31	2847.699	5.2	

Los dos primeros valores pasados son las columnas que se utilizarán, respectivamente, como índice de fila y de columna, y finalmente una columna de valor opcional para llenar el DataFrame. Supongamos que tiene dos columnas de valores que desea remodelar (reshape) simultáneamente:

In [111...]

```
long_data["value2"] = np.random.standard_normal(len(long_data))
long_data[:10]
```

Out[111...]

	date	item	value	value2
<b>0</b>	1959-01-01	realgdp	2710.349	0.802926
<b>1</b>	1959-01-01	infl	0.000	0.575721
<b>2</b>	1959-01-01	unemp	5.800	1.381918
<b>3</b>	1959-04-01	realgdp	2778.801	0.000992
<b>4</b>	1959-04-01	infl	2.340	-0.143492
<b>5</b>	1959-04-01	unemp	5.100	-0.206282
<b>6</b>	1959-07-01	realgdp	2775.488	-0.222392
<b>7</b>	1959-07-01	infl	2.740	-1.682403
<b>8</b>	1959-07-01	unemp	5.300	1.811659
<b>9</b>	1959-10-01	realgdp	2785.204	-0.351305

In [112...]

```
# Long_data.index.name = None
```

Omitiendo el último argumento, se obtiene un DataFrame con columnas jerárquicas:

In [113...]

```
pivoted = long_data.pivot(index="date", columns="item")
pivoted.head()
```

Out[113...]

	value				value2		
	item	infl	realgdp	unemp	infl	realgdp	unemp
	date						
1959-01-01	0.00	2710.349	5.8	0.575721	0.802926	1.381918	
1959-04-01	2.34	2778.801	5.1	-0.143492	0.000992	-0.206282	
1959-07-01	2.74	2775.488	5.3	-1.682403	-0.222392	1.811659	
1959-10-01	0.27	2785.204	5.6	0.128317	-0.351305	-1.313554	
1960-01-01	2.31	2847.699	5.2	-0.615939	0.498327	0.174072	

In [114...]

pivoted["value"].head()

Out[114...]

	item	infl	realgdp	unemp
	date			
	1959-01-01	0.00	2710.349	5.8
1959-04-01	2.34	2778.801	5.1	
1959-07-01	2.74	2775.488	5.3	
1959-10-01	0.27	2785.204	5.6	
1960-01-01	2.31	2847.699	5.2	

Tenga en cuenta que pivotar es equivalente a crear un índice jerárquico utilizando `set_index` seguido de una llamada a `unstack`:

In [115...]

```
unstacked = long_data.set_index(["date", "item"]).unstack(level="item")
unstacked.head()
```

Out[115...]

	value				value2		
	item	infl	realgdp	unemp	infl	realgdp	unemp
	date						
1959-01-01	0.00	2710.349	5.8	0.575721	0.802926	1.381918	
1959-04-01	2.34	2778.801	5.1	-0.143492	0.000992	-0.206282	
1959-07-01	2.74	2775.488	5.3	-1.682403	-0.222392	1.811659	
1959-10-01	0.27	2785.204	5.6	0.128317	-0.351305	-1.313554	
1960-01-01	2.31	2847.699	5.2	-0.615939	0.498327	0.174072	

## Pasar (Pivoting) del formato "ancho" (Wide) al "largo" (Long)

Una operación inversa al pivote para DataFrames es `pandas.melt`. En lugar de transformar una columna en muchas en un nuevo DataFrame, fusiona(merges) múltiples

columnas en una, produciendo un DataFrame más largo que el de entrada. Veamos un ejemplo:

```
In [116... df = pd.DataFrame({ "key": [ "foo", "bar", "baz"],  
                           "A": [ 1, 2, 3],  
                           "B": [ 4, 5, 6],  
                           "C": [ 7, 8, 9]})  
df
```

	key	A	B	C
<b>0</b>	foo	1	4	7
<b>1</b>	bar	2	5	8
<b>2</b>	baz	3	6	9

La columna "key" puede ser un indicador de grupo, y las otras columnas son valores de datos. Al utilizar `pandas.melt`, debemos indicar qué columnas (si las hay) son indicadores de grupo. Usemos aquí "key" como único indicador de grupo:

```
In [117... melted = pd.melt(df, id_vars="key")  
melted
```

	key	variable	value
<b>0</b>	foo	A	1
<b>1</b>	bar	A	2
<b>2</b>	baz	A	3
<b>3</b>	foo	B	4
<b>4</b>	bar	B	5
<b>5</b>	baz	B	6
<b>6</b>	foo	C	7
<b>7</b>	bar	C	8
<b>8</b>	baz	C	9

Usando `pivot`, podemos volver (reshape) al diseño original:

```
In [118... reshaped = melted.pivot(index="key", columns="variable",  
                           values="value")  
reshaped
```

Out[118... variable A B C

key
<b>bar</b> 2 5 8
<b>baz</b> 3 6 9
<b>foo</b> 1 4 7

Dado que el resultado de `pivot` crea un índice a partir de la columna utilizada como etiquetas de fila, es posible que deseemos utilizar `reset_index` para volver a mover los datos a una columna:

In [119... reshaped.reset\_index()

Out[119... variable key A B C

<b>0</b>	bar	2	5	8
<b>1</b>	baz	3	6	9
<b>2</b>	foo	1	4	7

También puede especificar un subconjunto de columnas para utilizarlas como columnas de valores:

In [120... pd.melt(df, id\_vars="key", value\_vars=["A", "B"])

Out[120... key variable value

<b>0</b>	foo	A	1
<b>1</b>	bar	A	2
<b>2</b>	baz	A	3
<b>3</b>	foo	B	4
<b>4</b>	bar	B	5
<b>5</b>	baz	B	6

`pandas.melt` también se puede utilizar sin ningún identificador de grupo:

In [121... pd.melt(df, value\_vars=["A", "B", "C"])

Out[121...]

	variable	value
<b>0</b>	A	1
<b>1</b>	A	2
<b>2</b>	A	3
<b>3</b>	B	4
<b>4</b>	B	5
<b>5</b>	B	6
<b>6</b>	C	7
<b>7</b>	C	8
<b>8</b>	C	9

In [122...]

```
pd.melt(df, value_vars=["key", "A", "B"])
```

Out[122...]

	variable	value
<b>0</b>	key	foo
<b>1</b>	key	bar
<b>2</b>	key	baz
<b>3</b>	A	1
<b>4</b>	A	2
<b>5</b>	A	3
<b>6</b>	B	4
<b>7</b>	B	5
<b>8</b>	B	6